

# INTERPRETOWALNOŚĆ | WYJAŚNIALNOŚĆ UCZENIA MASZYNOWEGO

---

Dr Robert Małysz

# WYKŁAD 7 - AGENDA

---

Metody przykładowe, oparte na regułach oraz kohortowe

1. Counterfactuals (Kontrfaktyczne przykłady)
2. Anchors (Reguły kotwiczące)

# WYKŁAD 7 – TAKSNOMIA XAI

## WYMIAR 1: SCOPE - ZAKRES WYJAŚNIENIA

### Global Methods

**Cel:** Zrozumienie całego modelu

PDP / ICE / ALE

Permutation Importance

H-statistic

Global Surrogate

SHAP Summary

### Local Methods

**Cel:** Wyjaśnienie pojedynczej predykcji

LIME

SHAP (local)

Counterfactuals

Anchors

Prototypes

### Cohort Methods

**Cel:** Analiza grup obserwacji

ICE clusters

Subgroup analysis

Group SHAP

Segment-wise PDP

# WYKŁAD 7 – TAKSNOMIA XAI

## WYMIAR 3: TECHNIQUE – TECHNIKA WYJAŚNIANIA

### Feature Attribution

**SHAP** - Shapley values

**LIME** - Local surrogate

**Integrated Gradients**

**LRP** - Layer-wise Relevance

### Partial Dependence

**PDP** - Partial Dependence

**ICE** - Individual curves

**ALE** - Accumulated effects

**SHAPDP** - SHAP dependence

### Feature Importance

**Permutation** - Shuffle & measure

**Gini/Entropy** - Tree-based

**Drop-column** - Retrain

**SHAP** - Mean |SHAP|

### Example-based

**Counterfactuals** - DiCE, WhatIf

**Prototypes** - Representative

**Influential** - Training impact

**Adversarial** - Edge cases

### Concept-based

**TCAV** - Concept vectors

**CBM** - Concept bottleneck

**ACE** - Automatic concepts

**NetDissect** - Unit semantics

### Surrogate Models

**Global** - Entire model

**Local (LIME)** - Per instance

**Anchors** - Rule-based

**Distillation** - Teacher-student

# WYKŁAD 7 – COUNTERFACTUALS

## WPROWADZENIE

### Definicja

Counterfactual (przykład kontrfaktyczny) to najbliższa możliwa modyfikacja cechy wejściowej instancji, która zmienia predykcję modelu na pożądaną klasę.

### Intuicja

"Co musiałoby się zmienić w danych wejściowych, aby otrzymać inną predykcję?"

### Przykład z aplikacją kredytową:

- **Obecna sytuacja:** Kredyt odrzucony
- **Pytanie:** Co muszę zmienić, aby otrzymać kredyt?
- **Counterfactual:** "Gdyby Twój roczny dochód był o 5000 PLN wyższy ORAZ gdybyś miał o 2 lata dłuższą historię kredytową, Twój kredyt zostałby zatwierdzony"

# WYKŁAD 7 – COUNTERFACTUALS

## PROBLEM OPTYMALIZACYJNY

### Problem optymalizacyjny

$$x' = \arg \min_{x'} \left[ L(f(x'), y_{target}) + \lambda \cdot d(x, x') + \sum_{j=1}^p w_j \cdot |x'_j - x_j| \right]$$

gdzie:

- $L(f(x'), y_{target})$  - funkcja straty
- $d(x, x')$  - odległość między instancjami
- $\lambda$  - parametr balansujący
- $w_j$  - wagi dla poszczególnych cech

### Przykład z aplikacją kredytową:

- **Obecna sytuacja:** Kredyt odrzucony
- **Pytanie:** Co muszę zmienić, aby otrzymać kredyt?
- **Counterfactual:** "Gdyby Twój roczny dochód był o 5000 PLN wyższy ORAZ gdybyś miał o 2 lata dłuższą historię kredytową, Twój kredyt zostałby zatwierdzony"

# WYKŁAD 7 – COUNTERFACTUALS

## ALGORYTM

### Algorytm generowania Counterfactuals (Wachter et al., 2017)

1. **Inicjalizacja:** Zaczniij od oryginalnej instancji  $x^{(0)} = x$

2. **Dla każdej iteracji  $t = 1, 2, \dots, T$ :**

- Oblicz gradient funkcji celu:

$$\nabla_x \mathcal{L}(x^{(t)}) = \nabla_x L(f(x^{(t)}), y_{target}) + \lambda \nabla_x d(x, x^{(t)})$$

- Aktualizuj kandydata:

$$x^{(t+1)} = x^{(t)} - \alpha \nabla_x \mathcal{L}(x^{(t)})$$

- Zastosuj ograniczenia (feasibility, immutability, categorical)
- Jeśli  $f(x^{(t+1)}) = y_{target}$  i jakość rozwiązania jest zadowalająca, STOP

3. **Zwróć:**  $x^* = x^{(T)}$  jako counterfactual

### Parametry

- $\alpha$  - learning rate (krok gradientu)
- $\lambda$  - waga odległości (proximity)
- $T$  - maksymalna liczba iteracji



# WYKŁAD 7 – COUNTERFACTUALS

## RÓŻNORODNOŚĆ WYJAŚNIEŃ

### Dlaczego wiele counterfactuals?

- Różni użytkownicy mogą preferować różne typy zmian
- Niektóre zmiany mogą być łatwiejsze do zrealizowania niż inne
- Zapewnienie większej elastyczności i zaufania do systemu

### Diverse Counterfactual Explanations (DiCE)

Optymalizuj zbiór  $k$  counterfactuals  $\{x'_1, x'_2, \dots, x'_k\}$ :

$$\min_{\{x'_i\}} \sum_{i=1}^k [L(f(x'_i), y_{target}) + \lambda_1 \cdot d(x, x'_i)] - \lambda_2 \cdot \text{diversity}(\{x'_i\})$$

Gdzie diversity można zmierzyć jako:

$$\text{diversity}(\{x'_i\}) = \frac{1}{k(k-1)} \sum_{i=1}^k \sum_{j=i+1}^k d(x'_i, x'_j)$$



# WYKŁAD 7 – COUNTERFACTUALS

## RÓŻNORODNOŚĆ WYJAŚNIEŃ

---

Przykład - różne counterfactuals dla aplikacji kredytowej:

1. CF1: Zwiększ dochód o 5000 PLN
2. CF2: Zmniejsz zadłużenie o 3000 PLN i zwiększ staż pracy o 1 rok
3. CF3: Zwiększ oszczędności o 10000 PLN i popraw credit score o 50 punktów

# WYKŁAD 7 – COUNTERFACTUALS

## Zalety:

- ✓ Bardzo intuicyjne dla użytkowników końcowych
- ✓ Dostarczają actionable insights (konkretne działania)
- ✓ Model-agnostic (działa z każdym modelem)
- ✓ Naturalne dla człowieka ("co gdyby...?")
- ✓ Mogą uwzględniać ograniczenia domenowe
- ✓ Zgodne z GDPR (prawo do wyjaśnienia)

## Wady:

- ✗ Kosztowne obliczeniowo (optymalizacja dla każdej instancji)
- ✗ Mogą sugerować nierealistyczne zmiany
- ✗ Brak gwarancji znalezienia rozwiązania
- ✗ Wrażliwe na dobór parametrów ( $\lambda$ , wagi cech)
- ✗ Nie wyjaśniają globalnego zachowania modelu
- ✗ Mogą istnieć nieskończenie wiele counterfactuals

# WYKŁAD 7 – COUNTERFACTUALS

## ZASTOSOWANIA PRAKTYCZNE

---

**Finanse:** Wyjaśnienie decyzji kredytowych

**Medycyna:** Alternatywne ścieżki leczenia

**HR:** Warunki akceptacji kandydata do pracy

**Marketing:** Optymalizacja profilu klienta

# WYKŁAD 7 – ANCHORS

## WPROWADZENIE

### Definicja

Anchor (reguła kotwicząca) to zbiór warunków (reguł decyzyjnych) dla instancji, które są wystarczające do "zakotwiczenia" predykcji, niezależnie od wartości innych cech.

### Intuicja

"Jakie warunki muszą być spełnione, aby predykcja była stabilna?"

### Przykład z klasyfikacją sentymentu recenzji filmu

- Predykcja: Pozytywna recenzja (95% pewności)
- Anchor:
  - IF "excellent" IN recenzja AND
  - IF "brilliant" IN recenzja
  - THEN predykcja = Pozytywna (z precision = 0.95)
- Interpretacja: Jeśli recenzja zawiera słowa "excellent" i "brilliant", model z 95% pewnością klasyfikuje ją jako pozytywną, niezależnie od innych słów w tekście

# WYKŁAD 7 – ANCHORS

## Definicja

Anchor  $A$  dla instancji  $x$  i predykcji  $f(x)$  to reguła, która spełnia:

$$\mathbb{E}_{\mathcal{D}(z|A)} [\mathbb{1}_{f(x)=f(z)}] \geq \tau$$

Gdzie:

- $\mathcal{D}(z|A)$  - rozkład instancji  $z$  spełniających warunek anchor  $A$
- $\mathbb{1}_{f(x)=f(z)}$  - funkcja wskaźnikowa (1 jeśli predykcje są takie same, 0 w przeciwnym wypadku)
- $\tau$  - próg precyzji (np. 0.95)

## Coverage (pokrycie)

$$\text{cov}(A) = \mathbb{E}_{\mathcal{D}(z)} [\mathbb{1}_{A(z)}]$$

Odsetek instancji w zbiorze danych, dla których anchor  $A$  jest spełniony

## Problem optymalizacyjny

# WYKŁAD 7 – ANCHORS

## PROBLEM OPTYMALIZACYJNY

### Problem optymalizacyjny

Znajdź anchor  $A^*$  maksymalizujący coverage przy ograniczeniu precision:

$$A^* = \arg \max_A \text{cov}(A) \quad \text{s.t.} \quad \text{prec}(A) \geq \tau$$

# WYKŁAD 7 – ANCHORS ALGORYTM

## Algorytm Anchors (Ribeiro et al., 2018)

**Główna idea:** Używamy beam search do eksploracji przestrzeni reguł

### 1. Inicjalizacja:

- Zaczynij z pustym anchor  $A = \emptyset$
- Kandydaci = wszystkie możliwe predykaty (warunki) dla instancji  $x$

### 2. Beam Search:

- Dla każdego kandydata  $A'$  w beam:
  - Generuj perturbacje spełniające  $A'$  poprzez próbkowanie  $z \sim \mathcal{D}(z|A')$
  - Oblicz precision:  $\text{prec}(A') = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{f(x)=f(z_i)}$
  - Oblicz coverage:  $\text{cov}(A')$
  - Jeśli  $\text{prec}(A') \geq \tau$ , zapisz  $A'$  jako kandydata
- Rozszerz najlepsze anchors o kolejne predykaty

3. **Zwróć:** Anchor z najwyższym coverage spełniający próg precision



# WYKŁAD 7 – ANCHORS ALGORYTM

---

Multi-Armed Bandit dla efektywności

Algorytm używa MAB (KL-LUCB) do efektywnego oszacowania precision bez próbkowania wszystkich możliwych perturbacji.

# WYKŁAD 7 – ANCHORS

## PRZYKŁAD

### Problem: Klasyfikacja ryzyka kredytowego

#### Instancja:

- Wiek: 35 lat
- Dochód: 75,000 PLN
- Stosunek zadłużenia do dochodu: 25%
- Credit score: 720
- Staż pracy: 5 lat

#### Predykcja modelu: NISKIE RYZYKO

#### Znaleziony Anchor (precision = 0.96, coverage = 0.35):

IF Credit score  $\geq 700$  AND Stosunek zadłużenia do dochodu  $\leq 30\%$

THEN Predykcja = NISKIE RYZYKO

#### Interpretacja

- Dla 96% klientów spełniających te dwa warunki, model przewiduje niskie ryzyko
- Te dwa warunki są wystarczające - inne cechy (wiek, dochód, staż) nie mają znaczenia
- 35% klientów w zbiorze danych spełnia te warunki

# WYKŁAD 7 – ANCHORS

## Zalety:

- ✓ Proste, interpretatywne reguły if-then
- ✓ Model-agnostic
- ✓ Uwzględniają interakcje między cechami
- ✓ Precyzja i pokrycie są łatwe do interpretacji
- ✓ Stabilne wyjaśnienia (robustness)
- ✓ Dobrze działają dla danych tabelarycznych, tekstowych i obrazów

## Wady:

- ✗ Kosztowne obliczeniowo (wymaga wielu predykcji)
- ✗ Mogą nie istnieć anchors o wysokim coverage
- ✗ Wybór progu precision  $\tau$  jest arbitralny
- ✗ Nie dostarczają informacji o kierunku wpływu
- ✗ Mogą tworzyć bardzo długie reguły (niska prostota)
- ✗ Wyjaśniają tylko lokalne zachowanie

# WYKŁAD 7 – ANCHORS VS LIME

Właściwość	LIME	Anchors
Typ wyjaśnienia	Model liniowy (wagi cech)	Reguły if-then
Interpretacja	Trudniejsza (współczynniki)	Łatwiejsza (reguły)
Stabilność	Niska (wrażliwe na perturbacje)	Wysoka (threshold-based)
Coverage	Tylko lokalne sąsiedztwo	Mierzalne i kontrolowane

# WYKŁAD 7 – PROTOTYPES

## WPROWADZENIE

---

### Definicja

Prototypes to reprezentatywne przykłady z danych treningowych, które najlepiej charakteryzują określone klasy lub regiony przestrzeni cech. Są to "typowe" instancje, które model używa do podejmowania decyzji.

# WYKŁAD 7 – PROTOTYPES WPROWADZENIE

## Typy metod opartych na przykładach

### 1. Prototypes

**Pytanie:** "Jakie przykłady najlepiej reprezentują daną klasę?"

- Typowe instancje klasy
- Reprezentatywne cechy
- Centroidy klastrów

### 2. Criticisms (Krytyki)

**Pytanie:** "Jakie przykłady są nietypowe lub źle reprezentowane?"

- Outliers
- Boundary cases
- Trudne przykłady

### 3. Influential Instances (Wpływowe przykłady)

**Pytanie:** "Które przykłady treningowe miały największy wpływ na tę predykcję?"

- Influence functions
- TracIn
- Representer Point Selection

# WYKŁAD 7 – PROTOTYPES

## MMD-CRITIC

### Maximum Mean Discrepancy (MMD)

MMD mierzy różnicę między dwoma rozkładami prawdopodobieństwa  $P$  i  $Q$  w przestrzeni RKHS:

$$\text{MMD}^2(P, Q) = \mathbb{E}_{x, x' \sim P}[k(x, x')] + \mathbb{E}_{y, y' \sim Q}[k(y, y')] - 2\mathbb{E}_{x \sim P, y \sim Q}[k(x, y)]$$

gdzie  $k(\cdot, \cdot)$  jest funkcją jądra (np. RBF)



# WYKŁAD 7 – PROTOTYPES

## ALGORYTM MMD-CRITIC (KIM ET AL., 2016)

### Faza 1 Wybór Prototypes

Znajdź podzbiór  $S \subset \mathcal{D}$  maksymalizujący:

$$\arg \max_{S, |S|=m} \text{MMD}^2(\mathcal{D}, S)$$

**Greedy selection:** Iteracyjnie dodawaj instancję maksymalizującą wzrost MMD

### Faza 2 Wybór Criticisms

Znajdź podzbiór  $C \subset \mathcal{D} \setminus S$  maksymalizujący:

$$\arg \max_{C, |C|=n} \text{witness}(C|S)$$

gdzie witness function identyfikuje regiony słabo pokryte przez prototypes

# WYKŁAD 7 – PROTOTYPES

## INFLUENCE FUNCTIONS

### Pytanie:

"Który przykład treningowy miał największy wpływ na predykcję dla konkretnej instancji testowej?"

### Influence Function (Koh & Liang, 2017)

Wpływ usunięcia instancji treningowej  $z$  na stratę dla instancji testowej  $z_{test}$ :

$$\mathcal{I}(z, z_{test}) = -\nabla_{\theta} L(z_{test}, \hat{\theta})^{\top} H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z, \hat{\theta})$$

Gdzie:

- $\hat{\theta}$  - parametry wytrenowanego modelu
- $L(\cdot, \theta)$  - funkcja straty
- $H_{\hat{\theta}} = \frac{1}{n} \sum_{i=1}^n \nabla_{\theta}^2 L(z_i, \hat{\theta})$  - macierz Hessego

### Interpretacja

- Dodatnia wartość  $\mathcal{I}(z, z_{test}) > 0$ : Usunięcie  $z$  zwiększyłoby stratę dla  $z_{test}$  (pozytywny wpływ)
- Ujemna wartość  $\mathcal{I}(z, z_{test}) < 0$ : Usunięcie  $z$  zmniejszyłoby stratę dla  $z_{test}$  (negatywny wpływ)

# WYKŁAD 7 – PROTOTYPES ZASTOSOWANIE W PRAKTYCE

---

- **Debugging:** Identyfikacja problemów z danymi treningowymi
- **Data auditing:** Wykrywanie błędnych etykiet
- **Zrozumienie modelu:** Jakie przykłady model uważa za typowe
- **Aktywne uczenie:** Wybór przykładów do etykietowania

# WYKŁAD 7 – PROTOTYPES

## Zalety:

- ✓ Bardzo intuicyjne (przykłady rzeczywiste)
- ✓ Nie wymagają znajomości cech/modelu
- ✓ Pomagają zrozumieć dane treningowe
- ✓ Użyteczne w debugowaniu modeli
- ✓ Naturalne dla ludzkiej percepcji (case-based reasoning)
- ✓ Mogą wykryć problemy z danymi

## Wady:

- ✗ Nie wyjaśniają dlaczego instancje są podobne
- ✗ Wrażliwe na wybór metryki odległości
- ✗ Kosztowne dla dużych zbiorów danych
- ✗ Influence functions: wymagają odwrotności Hessjanu ( $O(p^3)$ )
- ✗ Prototypes mogą nie być reprezentatywne przy złożonych danych
- ✗ Nie dostarczają informacji o ważności cech

# WYKŁAD 7 – PROTOTYPES

## Warianty metod Prototype

Metoda	Opis	Złożoność
k-NN	k najbliższych sąsiadów	$O(n)$ per query
MMD-critic	Prototypes + Criticisms	$O(n^2m)$
Influence Functions	Wpływ treningowy na test	$O(np^2 + p^3)$
TracIn	Tracing influence (gradients)	$O(nT)$ gdzie $T=\text{\#epochs}$

# WYKŁAD 7 – METODY KOHORTOWE

## WPROWADZENIE

---

### Definicja

Metody kohortowe (Cohort Methods) analizują zachowanie modelu dla grup podobnych instancji, zamiast pojedynczych obserwacji lub całego modelu globalnie.

### Motywacja

- **Globalne metody** (PDP, Feature Importance) mogą maskować heterogeniczność - różne grupy mogą reagować inaczej
- **Lokalne metody** (LIME, SHAP local) nie pokazują wzorców w grupach
- **Metody kohortowe wypełniają tę lukę: pokazują jak model zachowuje się dla różnych segmentów populacji**

# WYKŁAD 7 – METODY KOHORTOWE

## WPROWADZENIE

---

### Trzy główne podejścia

#### **Subgroup Analysis**

Analiza zachowania modelu w predefiniowanych grupach

#### **Segment-wise PDP**

Partial Dependence dla automatycznie wykrytych segmentów

#### **Group SHAP**

Agregacja wartości SHAP w grupach



# WYKŁAD 7 – METODY KOHORTOWE

## SUBGROUP ANALYSIS

### Definicja

Analiza wydajności i zachowania modelu w predefiniowanych lub odkrytych podgrupach danych.

### Typy subgroup analysis:

#### 1. **A priori** (z góry zdefiniowane grupy):

- Demografia: Wiek (młodzi/starsi), płeć, region
- Kliniczna: Ciężkość choroby, comorbidities
- Biznesowa: Nowi/stali klienci, segment rynku

#### 2. **Data-driven** (odkrywane z danych):

- Klasteryzacja instancji
- Decision tree subgroups
- ICE curve clustering

# WYKŁAD 7 – METODY KOHORTOWE

## SUBGROUP ANALYSIS

### Metryki do porównania

Dla każdej grupy  $G_k$ :

$\text{Performance}_k = \text{Accuracy}(G_k), \text{AUC}(G_k), \dots$

$\text{Feature Importance}_k = \text{PI}(\text{feature}_j, G_k)$

$\text{Fairness metrics}_k = \text{Disparate Impact}, \text{Equal Opportunity}$

# WYKŁAD 7 – METODY KOHORTOWE

## SUBGROUP ANALYSIS PRZYKŁAD

**Problem:** Model predykcji ryzyka sercowo-naczyniowego

**Grupy analizowane:**

G1: Wiek < 50 lat

G2: Wiek 50-65 lat

G3: Wiek > 65 lat

**Wyniki analizy:**

Grupa	AUC	Top Feature	Feature Importance
G1 (< 50)	0.82	Cholesterol	0.35
G2 (50-65)	0.88	Ciśnienie krwi	0.42
G3 (> 65)	0.76	Historia rodzinna	0.38

# WYKŁAD 7 – METODY KOHORTOWE

## SUBGROUP ANALYSIS PRZYKŁAD

### Wnioski kliniczne

- **Młodszy pacjenci:** Model opiera się głównie na poziomie cholesterolu
- **Wiek średni:** Ciśnienie krwi jest głównym predyktorem
- **Starsi pacjenci:** Model ma niższą dokładność, historia rodzinna staje się ważniejsza
- **Rekomendacja:** Model może wymagać rekaliibracji dla grupy G3

Grupa	AUC	Top Feature	Feature Importance
G1 (< 50)	0.82	Cholesterol	0.35
G2 (50-65)	0.88	Ciśnienie krwi	0.42
G3 (> 65)	0.76	Historia rodzinna	0.38

# WYKŁAD 7 – METODY KOHORTOWE

## SEGMENT WISE PDP

---

### Motywacja

Globalny PDP pokazuje średni efekt cechy, ale może maskować heterogeniczne efekty w różnych segmentach populacji.

# WYKŁAD 7 – METODY KOHORTOWE

## SEGMENT WISE PDP ALGORYTM

1. **Oblicz ICE curves** dla wszystkich instancji  $i = 1, \dots, n$ :

$$\text{ICE}_i(x_j) = f(x_j, x_{\setminus j}^{(i)})$$

2. **Klasteryzacja ICE curves:**

- Użyj k-means, hierarchical clustering lub innej metody
- Metryka odległości: np. Dynamic Time Warping, euclidean

3. **Dla każdego klastra  $C_k$ :**

$$\text{PDP}_{C_k}(x_j) = \frac{1}{|C_k|} \sum_{i \in C_k} \text{ICE}_i(x_j)$$

4. **Wizualizuj** segment-wise PDP curves dla każdego klastra

# WYKŁAD 7 – METODY KOHORTOWE

## SEGMENT WISE PDP

---

### Interpretacja:

- Każdy klaster reprezentuje segment populacji o podobnej reakcji na zmianę cechy
- Różnice między PDP klastrów pokazują heterogeniczność efektu
- Można zidentyfikować subpopulacje z różnymi wzorcami zachowań



# WYKŁAD 7 – METODY KOHORTOWE

## GROUP SHAP

---

### Motywacja

SHAP values dostarczają lokalnych wyjaśnień dla pojedynczych instancji. Group SHAP agreguje te wartości dla grup, pozwalając zrozumieć typowe wzorce wyjaśnień w kohortach.

# WYKŁAD 7 – METODY KOHORTOWE

## GROUP SHAP

### Definicja

Dla grupy instancji  $G = \{x^{(1)}, \dots, x^{(m)}\}$ , średnia wartość SHAP dla cechy  $j$ :

$$\text{GroupSHAP}_G(j) = \frac{1}{m} \sum_{i=1}^m \phi_j(x^{(i)})$$

Można również obliczyć:

- **Mediana:**  $\text{median}(\{\phi_j(x^{(i)})\}_{i=1}^m)$
- **Odchylenie standardowe:**  $\text{std}(\{\phi_j(x^{(i)})\}_{i=1}^m)$
- **Rozkład:** Histogram wartości SHAP w grupie

# WYKŁAD 7 – METODY KOHORTOWE

## GROUP SHAP

### Warianty agregacji

#### 1. Mean Absolute SHAP

$$\text{GroupSHAP}_G^{\text{abs}}(j) = \frac{1}{m} \sum_{i=1}^m |\phi_j(x^{(i)})|$$

Pokazuje średnią siłę wpływu (niezależnie od kierunku)

#### 2. Directional Agreement

$$\text{Agreement}_G(j) = \frac{|\sum_{i=1}^m \text{sign}(\phi_j(x^{(i)}))|}{m}$$

Mierzy konsensus co do kierunku wpływu (0-1)

# WYKŁAD 7 – METODY KOHORTOWE

## GROUP SHAP PRZYKŁAD

**Problem: Model predykcji churn (odejście klienta)**

**Grupy analizowane:**

- G1: Nowi klienci (< 6 miesięcy)
- G2: Klienci lojalni (> 2 lata)

**Group SHAP Analysis**

Cecha	G1: Nowi (mean SHAP)	G2: Lojalni (mean SHAP)	Różnica
Cena usługi	<b>+0.35</b>	+0.08	★★★
Jakość obsługi	-0.15	<b>-0.42</b>	★★
Liczba kontaktów	-0.05	-0.12	★
Program lojalnościowy	-0.02	<b>-0.38</b>	★★★

# WYKŁAD 7 – METODY KOHORTOWE

## GROUP SHAP PRZYKŁAD

### Interpretacja i wnioski:

- **Nowi klienci:** Bardzo wrażliwi na cenę (+0.35 SHAP), mniej na jakość obsługi
- **Lojalni klienci:** Jakość obsługi (-0.42) i program lojalnościowy (-0.38) są kluczowe
- **Rekomendacja:**
  - **Nowi:** Oferty cenowe, elastyczne plany
  - **Lojalni:** Inwestować w jakość obsługi i benefity lojalnościowe

Cecha	G1: Nowi (mean SHAP)	G2: Lojalni (mean SHAP)	Różnica
Cena usługi	<b>+0.35</b>	+0.08	★★★
Jakość obsługi	-0.15	<b>-0.42</b>	★★
Liczba kontaktów	-0.05	-0.12	★
Program lojalnościowy	-0.02	<b>-0.38</b>	★★★

# WYKŁAD 7 – METODY KOHORTOWE

## PORÓWNANIE

Metoda	Typ analizy	Grupy	Output	Zastosowanie
<b>Subgroup Analysis</b>	Model performance	Predefiniowane	Metryki per grupa	Fairness, debugging
<b>Segment-wise PDP</b>	Feature effect	Data-driven (ICE)	PDP curves per segment	Heterogeniczne efekty
<b>Group SHAP</b>	Feature attribution	Obie	Agregowane SHAP values	Porównanie grup

# WYKŁAD 7 – METODY KOHORTOWE

## PORÓWNANIE

### Kiedy używać której metody?

#### Subgroup Analysis

- ✓ Znasz istotne grupy (domena)
- ✓ Fairness / bias detection
- ✓ Regulatory requirements

#### Segment-wise PDP

- ✓ Odkrywanie ukrytych segmentów
- ✓ Heterogeniczne efekty cech
- ✓ Feature engineering insights

#### Group SHAP

- ✓ Porównanie wzorców wyjaśnień
- ✓ Feature importance per segment
- ✓ Personalizacja strategii

# WYKŁAD 7 – METODY KOHORTOWE

## PORÓWNIANIE

---

### Best Practices

- Zawsze sprawdź **rozmiar grupy** - małe grupy mogą dawać niestabilne wyniki
- Użyj **multiple testing correction** przy porównywaniu wielu grup
- **Wizualizuj rozkłady**, nie tylko średnie
- **Łącz metody dla pełniejszego obrazu**



# WYKŁAD 7 – METODY KOHORTOWE

## Zalety:

- ✓ Ujawniają heterogeniczność efektów
- ✓ Pomagają w wykrywaniu bias/fairness issues
- ✓ Umożliwiają personalizację strategii
- ✓ Łączą globalne i lokalne perspektywy
- ✓ Mogą odkryć nieoczekiwane subpopulacje
- ✓ Przydatne w regulatory/auditing contexts
- ✓ Dostarczają actionable insights per segment

## Wady:

- ✗ Wymagają wystarczającej liczby obserwacji per grupa
- ✗ Multiple testing problem (wiele porównań)
- ✗ Wybór grup może być arbitralny
- ✗ Data-driven segmentation może być niestabilna
- ✗ Zwiększona złożoność interpretacji
- ✗ Kosztowne obliczeniowo ( $k \times$  koszt metody bazowej)

# WYKŁAD 7 – PORÓWNANIE METOD

Metoda	Scope	Technique	Output	Główne zastosowanie
<b>Counterfactuals</b>	Local	Example-based	Alternatywne przykłady	Actionable recourse
<b>Anchors</b>	Local	Rule-based	Reguły if-then	Stabilne wyjaśnienia
<b>Prototypes</b>	Global	Example-based	Reprezentatywne przykłady	Zrozumienie klas
<b>Influence Functions</b>	Local	Example-based	Wpływowe przykłady	Debugging, data auditing
<b>Subgroup Analysis</b>	Cohort	Performance	Metryki per grupa	Fairness, bias detection
<b>Segment-wise PDP</b>	Cohort	Partial Dependence	PDP per segment	Heterogeniczne efekty
<b>Group SHAP</b>	Cohort	Feature Attribution	Agregowane SHAP	Porównanie grup

# WYKŁAD 7 – PORÓWNANIE METOD

---

## Wybór metody

1. **Pytanie:** Czy wyjaśnienie dla pojedynczej predykcji?
  - TAK → Counterfactuals (actionable) lub Anchors (stabilne)
  - NIE → Przejdź dalej
2. **Pytanie:** Czy interesują Cię konkretne grupy?
  - TAK → Metody kohortowe
  - NIE → Prototypes (reprezentacja) lub Influence (debugging)

# WYKŁAD 7 – PODSUMOWANIE

---

## 1. Counterfactuals - Best Practices

- Zawsze definiuj **immutable features** (wiek, płeć, historia)
- Używaj **diverse counterfactuals** (DiCE) dla większej użyteczności
- Waliduj **feasibility** z ekspertami domenowymi
- Rozważ **koszty** zmian różnych cech (nie wszystkie zmiany są równie łatwe)

## 2. Anchors - Best Practices

- Ustaw **threshold precision** zależnie od zastosowania (regulatory: wysokie, exploratory: niższe)
- Monitoruj **coverage** - niska coverage może wskazywać na zbyt specyficzne reguły
- Używaj dla **high-stakes decisions** gdzie stabilność jest kluczowa
- Łącz z LIME/SHAP dla pełniejszego obrazu

# WYKŁAD 7 – PODSUMOWANIE

---

## 3. Prototypes - Best Practices

- Zawsze pokazuj zarówno **prototypes** JAK I **criticisms**
- Użyj influence functions do **debugowania błędów** modelu
- Periodycznie sprawdzaj czy prototypes są **still representative** (data drift)
- Wizualizuj prototypes dla interpretacji (szczególnie dla obrazów/tekstu)

## 4. Metody Kohortowe - Best Practices

- Zapewnij **min. 100 obserwacji** per grupa dla stabilnych wyników
- Używaj **Bonferroni correction** lub FDR dla multiple testing
- Wizualizuj **confidence intervals**, nie tylko point estimates
- Dokumentuj **clinical/business significance**, nie tylko statistical

# WYKŁAD 7 – BIBLIOTEKI PYTHON

## Counterfactuals:

- **DiCE** - Diverse Counterfactual Explanations `pip install dice-ml`
- **Alibi** - Counterfactuals with RL `pip install alibi`

## Anchors:

- **Alibi** - Anchor implementation `pip install alibi`
- Anchor implementacja w **anchor-exp**

## Prototypes:

- **MMD-critic** - Prototypes selection
- **Captum** - Influence functions (PyTorch) `pip install captum`
- **TracIn** - Influence tracing

## Metody Kohortowe:

- **scikit-learn** - Clustering dla segmentation
- **SHAP** - Group SHAP analysis
- **PDPbox** - Segment-wise PDP

# ŹRÓDŁA

1. Wachter, S., Mittelstadt, B., & Russell, C. (2017). "Counterfactual Explanations Without Opening the Black Box" Harvard Journal of Law & Technology
2. Mothilal, R. K., Sharma, A., & Tan, C. (2020). "Explaining Machine Learning Classifiers through Diverse Counterfactual Explanations" FAT\* 2020
3. Karimi, A. H., et al. (2021). "Model-Agnostic Counterfactual Explanations for Consequential Decisions" AISTATS 2021
4. Ribeiro, M. T., Singh, S., & Guestrin, C. (2018). "Anchors: High-Precision Model-Agnostic Explanations" AAAI 2018
5. Kim, B., Khanna, R., & Koyejo, O. (2016). "Examples are not Enough, Learn to Criticize! Criticism for Interpretability" NeurIPS 2016
6. Koh, P. W., & Liang, P. (2017). "Understanding Black-box Predictions via Influence Functions" ICML 2017
7. Pruthi, G., et al. (2020). "Estimating Training Data Influence by Tracing Gradient Descent" NeurIPS 2020
8. Goldstein, A., et al. (2015). "Peeking Inside the Black Box: Visualizing Statistical Learning With Plots of Individual Conditional Expectation" JCGS 2015
9. Kumar, I. E., et al. (2020). "Problems with Shapley-value-based Explanations as Feature Importance Measures" ICML 2020



# ŹRÓDŁA

## Online

1. <https://christophm.github.io/interpretable-ml-book/>
2. <https://shap.readthedocs.io/>
3. <https://shap.readthedocs.io/en/latest/overviews.html>

## Regulacje

1. EBA/REP/2023/28: Report on ML for IRB models
2. SR 11-7: Guidance on Model Risk Management
3. KNF: Rekomendacja P